# Programació en Scripting: Pràctica final



Generador d'informes sobre la variació dels assalariats que teletreballen segons lloc, període i sexe

Àlex Franco Granell afrancogranell

# Índex

A. Objectius del projecte:	3
3. Objectius dels scripts:	
1. script a.sh	
2. script b.sh	
3. script b.awk	
4. script b1.awk	
5. script c.awk	
6. script run.sh.	
C. Taula de resultats:	
D. Resultat de l'script:	
E. Diagrama de Flux:	
F. Avaluació del projecte:	

# A. Objectius del projecte:

He elaborat aquest projecte en base a les necessitat que he experimentat com a periodista. En aquest treball és molt important tenir resultats el més aviat possible i tenir a l'abast un script que et processe informació de l'INE és molt útil.

Particularment em vaig fixar que a partir de la pandèmia s'ha augmentat considerablement el teletreball a les empreses. Tant és així, que s'ha parlat del fenomen unes quantes vegades als mitjans. Així doncs, em vaig decidir per crear un script que em permetera comparar el nombre de treballadors assalariats que han teletreballat en algun moment de l'any, per veure l'evolució d'aquesta tendència laboral.

Com és un tema d'actualitat del qual cada vegada desperta més interès, els periodistes és segur que li van a fer un seguiment. És per això que base el meu script a partir de les dades que publica l'INE, ja que sempre van a mantenir el mateix format incrementant el nombre d'anys. (<a href="https://datos.gob.es/es/catalogo/ea0010587-asalariados-por-frecuencia-con-la-que-trabajan-en-su-domicilio-particular-sexo-y-comunidad-autonoma-valores-absolutos-epa-identificador-api-37024">https://datos.gob.es/es/catalogo/ea0010587-asalariados-por-frecuencia-con-la-que-trabajan-en-su-domicilio-particular-sexo-y-comunidad-autonoma-valores-absolutos-epa-identificador-api-37024</a>)

L'objectiu principal d'aquest projecte és que a partir de la descàrrega del *dataset* més actualitzat de treballadors assalariats que han treballat al seu domicili es puga comparar ràpidament l'evolució dels treballadors de dues autonomies i comparar-les amb el total d'Espanya. Es vol veure com evoluciona aquesta tendència en el temps.

A més, les dades que es pretenen analitzar contenen informació per sexe. Per tant es pot veure també un anàlisi del mercat laboral en aquesta perspectiva.

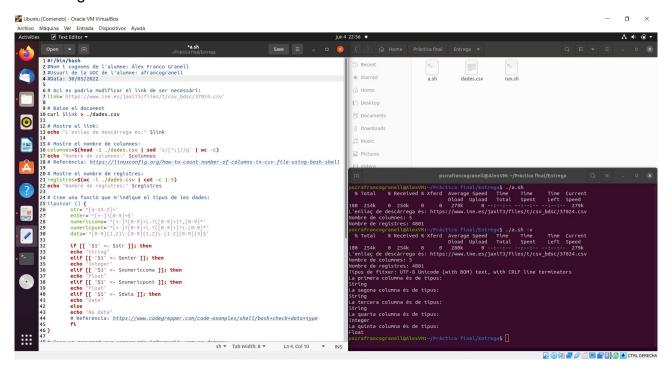
Considere que és un projecte adequat per a un treball *d'scripting* perquè les dades mantindran sempre la mateixa estructura, i cada any es podrà veure de manera senzilla l'increment periòdic de les dades. Sols s'haurà d'inserir el nou enllaç i canviar els valors de l'any analitzat i les autonomies observades.

S'ha de tenir present una característica important del *dataset* seleccionat. Tot i que les dades mostren correctament l'augment de treballadors que teletreballen (punt principal d'estudi), les dades recollides per l'INE representen els treballadors que han treballat al seu domicili. No té perquè ser el mateix. Així mateix, en aquest s'hi veu la creixent tendència de treballar des de la llar. Es pot considerar que ambdós punts de vista són essencialment el mateix, ja que es tracta de treballar en un lloc suposadament de descans, i no en una fàbrica o una oficina. Dic tot això per no generar confusions, per exemple, amb el teletreball d'oficina que es fa a través d'internet. Ex: una persona fent calçat a casa està treballant al seu domicili, al igual que un programador web. En aquest projecte es considerarà teletreball a totes les persones assalariades que treballen a la llar.

# **B.** Objectius dels scripts:

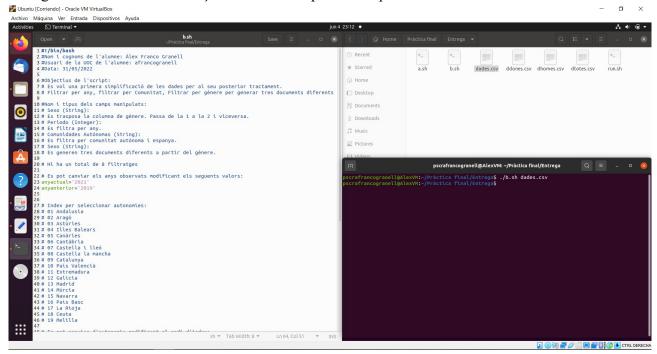
### 1. script a.sh

Com s'indicava a l'enunciat de la pràctica final, aquest script baixa les dades segons l'enllaç que s'indique. Amb l'opció -v mostra el tipus de cada columna i el tipus de fitxer descarregat

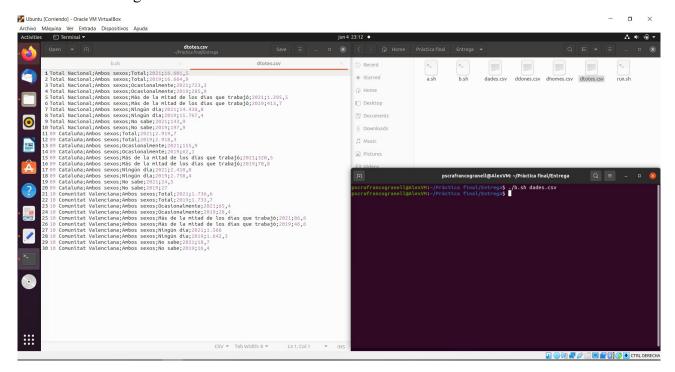


### 2. script b.sh

Aquest script realitza un primer filtratge de les dades. És el que s'encarrega de la selecció del període a analitzar, així com les dues autonomies que es voldran comparar amb Espanya. Per a cada sexe genere un csv diferent. Açò serà rellevant per a *l'script* C

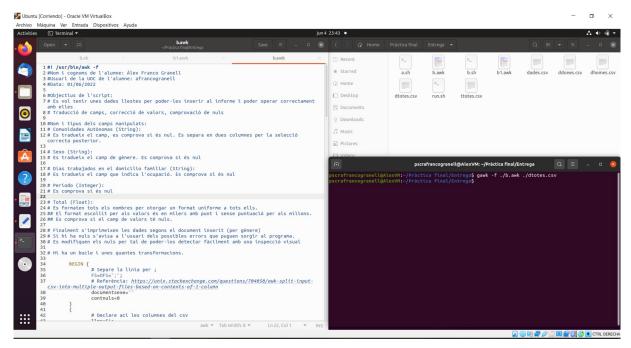


### El resultat és el següent:

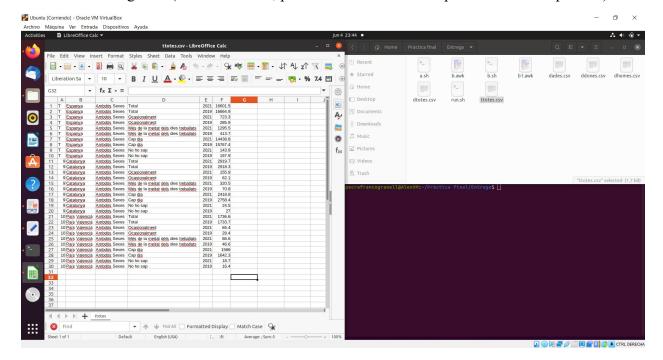


### 3. script b.awk

Aquest script s'encarrega de traduir tots els camps de text, corregir el format dels valors numèrics i fer una comprovació dels camps buits o nuls. Es vol una comprovació de la qualitat de la dada, per assegurar-nos que es pot executar correctament el programa. És especialment rellevant el tractament del format dels numèrics, ja que ens assegura que després per fer càlculs no hi haurà cap error (ja que les dades estan inserides en molts formats diferents). De trobar Nuls s'imprimirà un avís al *shell* on l'usuari haurà de comprovar les dades indicades per veure com procedir. També es genera una columna d'índex que serà utilitzada per l'script següent.

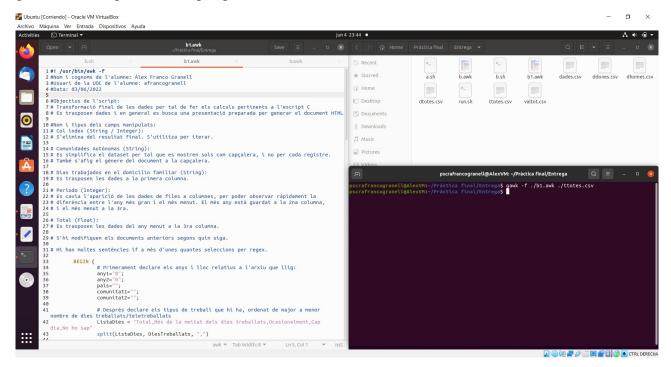


El resultat és el següent: (Guardat en csv, però es visualitza a excel per una fàcil comprensió)

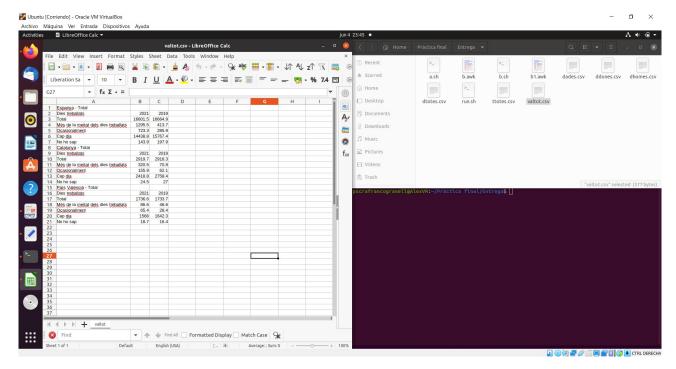


### 4. script b1.awk

Aquest script s'encarrega de la formatació final de les dades per la seua presentació. Es guarda el lloc com a capçalera de cada dada, i la columna dels anys passa a ser dues: una per l'any més recent i l'altra per a l'anterior. S'afegeix també a la primera columna els registres dels dies treballats. En general es transposen dades per generar l'estructura final

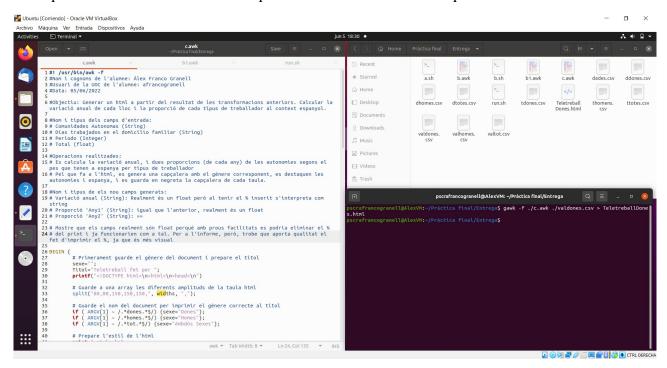


El resultat és el següent: (Guardat en csv, però es visualitza a excel per una fàcil comprensió)



### 5. script c.awk

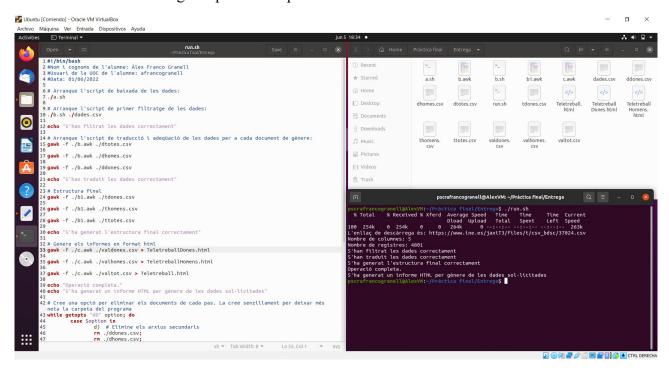
Aquest script s'encarrega de fer els càlculs desitjats per l'anàlisi de les dades, a més de guardar aquests a un fitxer HTML. Es calcula la variació anual de cada lloc respecte al període (Variació anual), i també la proporció que representava cada autonomia respecte a espanya en quant a treballadors que treballen al seu domicili (Proporció Any1 i Proporció Any2). Es genera un informe en HTML per cada gènere, així l'analista pot consultar les dades que li siguen més adients sense tenir que cercar molt a l'arxiu. Trobe que així és més visual i senzill per fer l'anàlisi.



Nota: Analitzaré els resultats a l'apartat D

### 6. script run.sh

Aquest script s'encarrega d'executar cada script descrit anteriorment i d'avisar a l'usuari de l'execució correcta de cadascun. He afegit dues opcions per al tractament dels fitxers de transformació. L'opció que està pensada per ser executada habitualment és la de -d, ja que aquesta deixa les dades d'origen i els resultats en HTML; els resultats de les transformacions són eliminats. Finalment també s'ha afegit l'opció de -D per deixar sols els resultats.



### C. Taula de resultats:

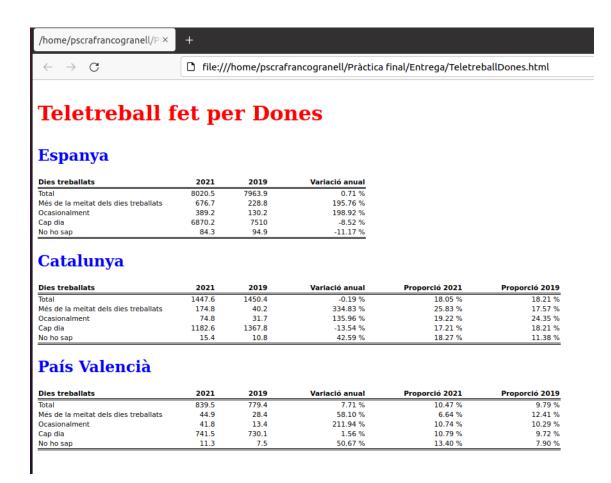
S'interpreten els camps segons l'estructura final generada per b1.awk

Camp	Operació	Camp generat
Valors corresponents a l'any1 i 2 per cada tipus	Es fa un càlcul de la variació anual.	(Variació anual): Es guarda en percentatge.
de dies treballats a la llar. Es repeteix per cada lloc	Concretament l'operació és ((anymajor/anymenor)-1)*100)	S'hi pot veure el canvi anual dels treballadors assalariats
		segons tipus
Valors corresponents al tipus de treball segons	Es calcula la proporció que representava el tipus de treball en	Proporció Any1 / Any2
lloc i any	l'autonomia segons el mateix periode a espanya.	Proporció dels treballadors autonòmics segons els
	Concretament l'operació és	espanyols del mateix tipus.
	((tipusautonomia1*100)/	S'hi veu clarament el pes dels
	tipusespanya)	treballadors autonòmics en el conjunt estatal

# D. Resultat de l'script:

Com he explicat anteriorment, genere tres informes segons el gènere dels treballadors perquè considere que és més senzill per l'anàlisi posterior de les dades. En aquest exemple mostraré solament el resultat de Dones. La resta són equivalents però amb les dades respectives del gènere.

Amb l'estructura aconseguida es veu ràpidament la variació de cada lloc en percentatge, i la proporció de cada autonomia segons els anys introduïts. Com comentava al plantejament dels objectius, el teletreball ha augmentat molt a causa de la pandèmia, i és per això que he escollit aquests anys per a l'exemple. Al 2019 no hi havia pandèmia, i al 2021 no hi havia confinament obligatori. Per tant amb aquestes dades es vol veure com s'ha transformat el mercat laboral del teletreball (assalariats que treballen a casa, com comentava prèviament).



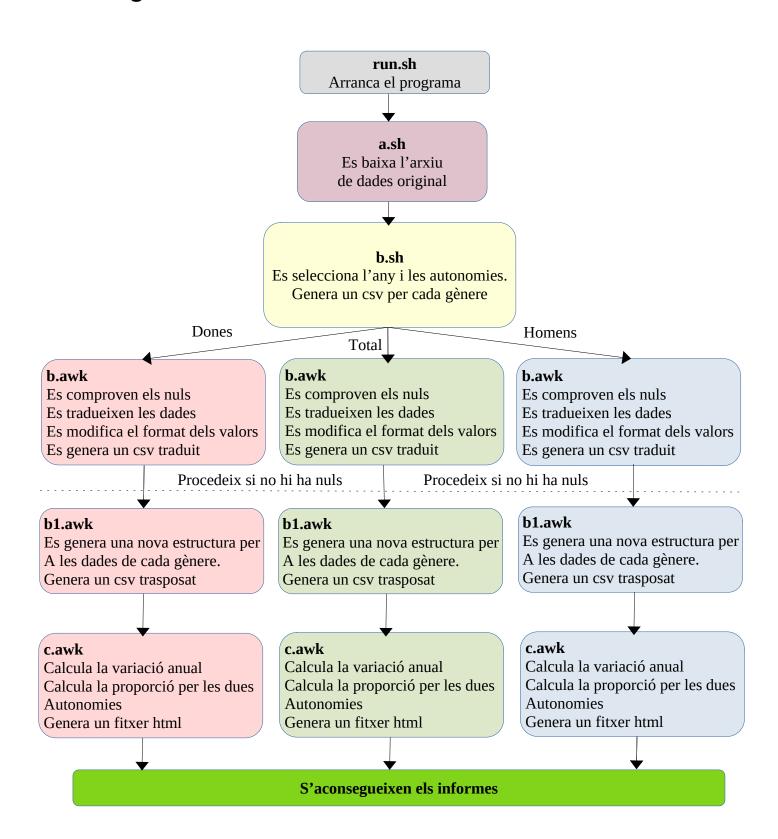
A través d'una inspecció de les dades s'hi veu que el nombre de dones teletreballant ha augmentat considerablement. A Catalunya s'hi veu un clar augment del teletreball amb un +300% de creixement per a les que més teletreballen. Al País Valencià s'hi veu també un augment, però més tímid, ja que l'increment principal es produeix als treballadors que teletreballen ocasionalment. (58% més de la meitat dels dies i un 211.9% de les treballadores ocasionals)

Al capdavall a l'anàlisi de les proporcions s'hi veu que Catalunya ha passat a representar el 25% de les treballadores que teletreballen a l'estat, mentre que el País Valencià ha reduït la seua posició fins al 6.6% (d'un 12.4% previ). Aquestes dades són rellevants perquè s'hi veu també que el País Valencià ha augmentat més les dones treballadores que Catalunya (Valors totals de la proporció de cat i val). Per tant se'ns indica que els nous llocs de treball als quals han accedit les dones en aquest període no és essencialment telemàtic.

Al capdavall s'hi veu que aquest script és útil per agregar les dades de dues autonomies i poder-les comparar entre elles, i amb el conjunt estatal. Com s'ha vist anteriorment, amb un breu anàlisi s'aconsegueix molta informació. A més, cal recordar que aquest anàlisi sols és d'un dels tres arxius. Trobe que és un bon resultat amb els objectius proposats, ja que a partir d'ara es podria anar inserint els nous enllaços que genere l'INE amb informació actualitzada i fer un seguiment de l'activitat laboral a la llar.

Finalment, destaque el bon exemple perquè s'hi pot veure amb claredat que als anys de la pandèmia hi va haver una gran transformació del mercat laboral; amb una creixent demanda de teletreball.

# E. Diagrama de Flux:



# F. Avaluació del projecte:

Al capdavall considere que és un bon script per els objectius proposats. Crec a més que s'ajusta a l'enunciat. Les dificultats principals que he trobat en la realització del projecte han sigut sobretot de gestió de temps. M'he posat a fer el projecte massa tard i això m'ha fet tenir una jornada intensa per traure'l correctament. Així mateix, crec que he aconseguit bons resultats.

Per scripts, de l'a al b.sh no he trobat molta complicació per fer-los, sols temps. Els que sí m'han marejat prou han sigut la resta. El problema principal que vaig tenir és que un primer moment volia generar l'estructura amb bash, i em vaig calfar prou el cap fins que al final ho vaig decidir fer amb awk (perquè és molt més senzill, al meu pareixer i per la meua experiència). A més també em vaig adonar que si no corregia correctament els valors no podia agregar bé els nombres ja que alguns es llegien com a text. Un calvari.

Sembla trivial, però de tot el treball, crec que el més clau és el formatar els nombres. Ho crec així perquè dóna després molts problemes a l'hora d'executar-ho. Fins i tot m'he adonat d'un error en les dades que no havia detectat on els milions també es guarden com [0-9]\.[0-9]{2} i l'he hagut de corregir a última hora. Si hi ha una part que pot fallar del programa, clarament ha de ser en aquest punt.

La resta doncs relativament bé. Deixant de costat b.awk i b1.awk, l'script final m'ha suposat treballar molt amb html tot i que no l'havia practicat encara. Un poc per falta de temps, culpa meua, no l'he pogut perfilar un poc més. Tot i que el veig prou presentable. Així i tot estic satisfet amb els resultats.

Pel que fa a les possibles millores del projecte, doncs crec que es podria treballar un poc millor amb els informes. Per exemple concatenant els resultats a una sola pàgina web i d'ahi ja poder escollir entre els tres diferents, o bé mostrar alguna gràfica d'evolució dels treballadors. Així i tot, jo crec que, en vista dels objectius presentats i el cas periodístic explicat, el més interessant seria crear un script que vigile cada dia la pàgina de l'INE en busca d'una actualització de les dades, i que les baixe i processe si en detecta. Això ja seria molt interessant. De moment, però, la selecció del link i dels valors és manual. També es podria modificar això per poder seleccionar les autonomies i els anys a partir d'un imput a la shell (confesse que volia fer-ho, però al veure que les crides estaven restringides tenia por a perdre punts per introduir variables posicionals o inputs. És per això que ho he deixat així)

Amb tot, he aprés que awk és molt versàtil, a generar arxius HTML a partir de csv, i les possibilitats que desperta l'scripting per l'automatització de tasques complexes de tractament de dades.